


MAZU — 真实事件核验

针对老师们提供的2025年真实事件清单，对模型进行的核验。方法统一：把 `forecast_tool` 的实时预测结果，与我们原始数据集里对应日期的真实指标直接对比——没有任何数字是编造的。

1. 达曼 (Dammam) — 沙尘暴 (2025年5月17-19日) 命中

信息来源 (NCM官方报告)： 5月16-19日全国性持续沙尘过程，峰值在5月19日，东部地区（含达曼）受影响最严重。




结果： 模型对5月17日给出了0.94的概率（基于5月16日的数据）——而5月17日达曼当地格点自己的探测得分正好是0.60（超过0.55的阈值，说明达曼当地确实发生了沙尘天气）。5月18日模型同样给出了较高概率（0.91）。但到了5月19日（信息来源所说的"全国峰值日"），达曼当地格点的风速已经减弱（实际风速降到2.1 m/s）——模型也相应给出了较低概率（0.05），是正确的。

原因： 在一次持续4天的全国性事件中，沙尘系统会在国土上移动——不是每个城市都在同一天达到峰值。达曼自己的峰值在5月17日，而全国性峰值出现在5月19日的其他地区。模型的判断是**准确的**，只是"全国峰值日"和"该城市自身峰值日"是两个不同的概念。

2. 达曼 — 高温热浪 (2025年6月13日) 部分命中

信息来源： 6月13日东部地区（Al-Ahsa录得49.3°C）刷新气温纪录，全国发布橙色预警。



结果：模型对6月13日给出了0.67的概率——超过0.55的业务阈值，也就是说系统会在这一天发出预警，方向正确。当天达曼当地格点的实际最高气温也处于附近几日中的高值（40.0°C；比Al-Ahsa的官方记录49.3°C低，因为这是两个不同的城市/格点，并非同一位置）。


更严格的独立核验（更新）：用与沙尘暴案例完全相同的、基于规则引擎（DetectionEngine，独立于机器学习模型）的核验方法重新检查后发现——达曼格点在整个6月10-16日窗口内，`risk_field` 逐日得分均为 **0.0**，因为规则引擎对高温热浪要求 `tmax_c ≥ 45°C`，而达曼在此期间的最高值仅为 44.2°C（6月16日），全程未达到该阈值。也就是说，规则引擎意义上的“达曼本地真实探测到热浪”这一说法**不成立**；此前“命中”的判断，依据的是模型概率超过业务阈值 + 当地气温相对偏高这一较弱证据，并未像沙尘暴案例那样经过规则引擎的独立交叉验证。

原因：模型在方向上（高风险、超过阈值）的判断本身没有问题，系统确实会发出预警。但这次核验也暴露了我们此前对两个案例采用了不同严格程度的验证标准——这里如实更正，而不是隐瞒。真实的 45°C+极端记录出现在Al-Ahsa，并非我们建模的8个城市之一，坐标差异是根本原因。

3. 吉达 (Jeddah) — 历史性特大洪水 (2025年12月9-10日)

未命中 — 真实局限

信息来源：6小时累计降雨179毫米（当地年均降雨量仅55.6毫米），为全年最严重的洪灾。



结果：无论是模型给出的概率（最高仅0.15，远低于0.5的阈值），还是我们原始数据集中吉达当地格点的实际降雨量（仅7.7毫米，扩大到整个区域搜索，最高也只有31.6毫米），都没有反映出这次事件。这不是“模型判断错误”，而是**原始数据本身就没有记录到这次事件**。

最可能的原因：我们使用的10公里网格，对于像6小时这种短时、高度局地化的强对流降水事件，可能会把它“平均”掉——点状气象站的实测值和10公里网格的面平均值之间，在这类事件上可能存在很大差异。这不是方法上的错误，而是**数据空间分辨率的真实局限**——这与老师们之前问到的“10公里网格 vs 街区级分辨率”问题直接相关。

总体结论

事件	结果	主要原因
达曼沙尘暴（5月17日）	命中	城市自身峰值与全国峰值日期不同，两者判断都准确
达曼高温热浪（6月13日）	部分命中	模型概率正确超阈值，但规则引擎独立核验在达曼格点全程为0——验证严格度不一致，已更正
吉达特大洪水（12月9-10日）	未命中	10公里网格对短时局地强对流事件的“平均”效应——真实的、已披露的数据分辨率局限

总体结论：3个事件中1个被模型和规则引擎双重准确捕捉（沙尘暴）；1个模型方向正确但规则引擎独立核验未能在同一严格标准下确认（热浪，已更正说明）；1个未能捕捉，其原因也能从技术上具体说明（数据分辨率）。相比“一切完美”的说法，这样的结果更有说服力，因为每一条结论——包括这次对我们自己验证方法不一致之处的更正——都可以从原始数据重新验证得出。